

UNIVERSITE D'ABOMEY-CALAVI (UAC)

FACULTE DES SCIENCES ET TECHNIQUES (FAST)

ENERGIES RENOUVELABLES ET SYSTEMES ENERGETIQUES
(ERSE)

UE : Méthodes statistiques d'analyse de données

ECUE : Statistique Univariée

ECUE : Statistique Bivariée

FILIERE : L1-(ERSE-FAST)

Enseignant : Dr. TOYOU L. Robert

TEL : 0167680382

Email : robert.toyou@imsp-uac.org

ANNEE ACADEMIQUE : 2025-2026

◀ PAS BESOIN D'ÊTRE GÉNIE AVANT DE RÉUSSIR ! ▶

Syllabus du cours

1. INFORMATIONS UTILES

Domaine de connaissance	: ERSE
Spécialité du diplôme	: Licence
Unité d'enseignement	: Méthodes statistiques d'analyse de données
Semestre	: 2
Durée	: 30h
Noms et grade de l'enseignant	:
Nom et Prénoms	: TOYOU Lawouè Robert
Spécialité	: Equations aux Dérivées Partielles et Applications
Grade	: Doctorat

2. Objectifs du cours

(a) Objectif général

Ce module de cours permettra à l'apprenant, une familiarisation avec les outils nécessaires et indispensables à l'organisation, à la présentation, à l'analyse, à l'interprétation et à la construction de résumés numériques et graphiques des données statistiques ; voire l'élaboration de modèle statistique.

(b) Objectifs spécifiques

Spécifiquement celui-ci acquerra les connaissances scientifiques pour :

- dépouiller les observations brutes recueillies par une étude statistique,
- organiser et prétraiter les données statistiques (préparation des données),
- construire et lire de façon pertinente des tableaux relevant des études statistiques dans différents domaines théoriques tout comme pratiques de la vie courante,
- déterminer les indicateurs pertinents d'une série statistique,
- résumer graphiquement et numériquement des données issues d'une étude statistique,
- analyser, interpréter et contextualiser les résultats d'une étude statistique,
- comparer des séries statistiques issues de différentes études ou une série statistique à une distribution statistique théorique,
- appliquer quelques méthodes de regression simple.

3. Contenu du cours

(a) Statistique Univariée :

- Terminologies-définition,
- Traitements numériques,
- Traitements graphiques,
- Caractéristiques de position et de dispersion.

(b) Statistique Bivariée .

- Introduction,
- Nuage de point associé à une série double,
- Point moyen,
- Ajustement linéaire : méthode des moindres carrées,
- Ajustement linéaire : méthode des points moyens de Mayer,

4. Approche pédagogique

- Cours Théorique ;
- Travaux Dirigés ;
- Travaux personnels d'étudiant .

5. Mode d'évaluation

Examen écrit :

- Au moins un devoir à la fin de l'UE et ou du semestre ;
- un examen de rattrapage à la fin de l'année.

6. Références bibliographiques

- (a) A. Ayache et J. Hamonier ; Statistique Descriptive et Calcul de Probabilités ; Université de Lille-France 2014.
- (b) Jean-Piere Lecoutre ; Statistique et Probabilités, cours et exercices corrigés ; Dunod 2012.
- (c) Gilbert Saporta ; Probabilité, Analyse des données et Statistiques ; Edition Tecchnip 1990.
- (d) Murray Spiegel ; Théorie et applications de la statistique ; Série Schaum 1972.

Table des matières

1	Statistique Univariée	6
1.1	Terminologies-définitions	6
1.1.1	Individu-Échantillon-Population	6
1.1.2	Caractère-Modalités	7
1.1.3	Variable statistique	8
1.2	Traitement numérique	8
1.2.1	Fréquences	8
1.2.2	Tableaux statistiques	9
1.2.3	Plus petite modalité-Plus grande modalité-Etendue	9
1.3	Traitements graphiques	10
1.3.1	Diagramme en bâtons (cas discret)	10
1.3.2	Les histogrammes	11
1.3.3	Polygone des fréquences ou des effectifs	11
1.3.4	Polygone des fréquences cumulées (ou effectifs cumulés)	11
1.3.5	Fonction de répartition d'une variable statistique discrète	12
1.3.6	Fonction de répartition d'une variable continue	12
1.4	Caractéristique de position et de dispersion	13
1.4.1	Le mode et la classe modale	13
1.4.2	La médiane-La classe médiane	13
1.4.3	La moyenne arithmétique	14
1.4.4	Les autres moyennes	14
1.4.5	Les quantiles	15
1.4.6	Les caractéristiques de dispersion	16
1.4.7	Paramètres de forme	17
1.5	Quelques exercices	18
2	Statistique Bivariée	21
2.1	Introduction	21
2.2	Nuage de point associé à une série double	22
2.2.1	Représentation par points pondérés	22
2.2.2	Représentation par tâches	22
2.3	Point moyen	22

2.4	Ajustement linéaire : Méthode des moindres carrées	23
2.4.1	Covariance	23
2.4.2	Coefficient de corrélation	23
2.4.3	Droite de régression de Y en X	23
2.4.4	Droite de régression de X en Y	24
2.5	Ajustement linéaire : Méthode des points moyens de Mayer	24
2.6	Quelques exercices	24

STATISTIQUE UNIVARIÉE

1.1 Terminologies-définitions

On appelle **Statistique** l'ensemble des méthodes (ou encore des techniques) permettant d'analyser (on dira plutôt de traiter) des ensembles d'observations (nous parlerons de données).

Les méthodes en question relèvent essentiellement des mathématiques et font largement appel à l'outil informatique pour leur mise en œuvre.

Pour éviter toute confusion, on notera la distinction entre la Statistique, au sens défini ci-dessus, et une statistique, terme parfois utilisé pour désigner des "données statistiques"; par exemple, on parle de la statistique du commerce extérieur d'un pays. Dans la suite de ce cours, nous n'utiliserons pas le terme de statistique dans ce dernier sens.

De manière un peu approximative, il est possible de classer les méthodes statistiques en deux groupes : celui des méthodes descriptives et celui des méthodes inférentielles.

- **La statistique descriptive.**

On regroupe sous ce terme les méthodes dont l'objectif principal est la description des données étudiées. Cette description des données se fait à travers leur présentation (la plus commode et la plus synthétique possible), leur représentation graphique et le calcul de résumés numériques (ou caractéristiques numériques). Dans cette optique, aucune hypothèse de type probabiliste n'est faite sur les données considérées (par exemple, il n'est pas nécessaire de supposer que les données sont les observations d'une loi normale). Les trois directions signalées ci-dessus (présentation, représentations graphiques et calcul de résumés numériques) serviront de guide dans la suite de ce cours.

On notera que les termes de statistique descriptive, statistique exploratoire et analyse des données sont quasiment synonymes.

- **La statistique inférentielle.**

Ce terme regroupe les méthodes dont l'objectif principal est de préciser un phénomène sur une population globale, à partir de son observation sur une partie restreinte de cette population (penser aux sondages). D'une certaine manière, il s'agit donc d'induire (ou encore d'inférer) du particulier au général. Le plus souvent, ce passage ne pourra se faire que moyennant des hypothèses de type probabiliste.

Les termes de statistique inférentielle, statistique mathématique et statistique inductive sont eux aussi quasiment synonymes.

Cette partie de la statistique, plus délicate, n'est pas traitée dans ce document. D'un point de vue méthodologique, on notera que la statistique descriptive précède en général la statistique inférentielle dans une démarche de traitement de données : ces deux aspects de la statistique se complètent bien plus qu'ils ne s'opposent.

1.1.1 Individu-Échantillon-Population

Toute réalité (physique ou non) possédant un aspect particulier ou une caractéristique particulière faisant l'objet d'une étude statistique est appelée un **individu** ou une **unité statistique**. Il est identifiable sans ambiguïté par cette caractéristique; on le notera souvent ω .

Exemple 1.1. *Un ménage, une pomme de terre, une entreprise, un homme, un pays, un bétail, etc.*

L'ensemble de tous les individus concernés par une étude statistique est appelé la **population** ; on note souvent Ω la population d'une étude statistique. Cet ensemble peut être fini ou infini (mais souvent vaste). Son cardinal est appelé **l'effectif total** ou la taille de la population statistique et souvent noté N ($\text{card}\Omega = N$).

Généralement, une étude statistique (ou la mesure pendant cette étude) n'est pas réalisée au niveau de tous les individus de la population. Si c'est le cas, l'étude statistique porte le nom de **recensement**. Sinon, le statisticien restreint son étude à une partie de la population qu'on appelle une **échantillon** ; ici, on dit qu'on a fait **un sondage**. Plus généralement, on parle **d'enquête statistique** quand il s'agit d'une étude statistique.

Toute liste d'observations faites au cours d'une étude statistique est appelée **série statistique**.

Remarque 1.2.

On a les relations suivantes :

$$\text{Echantillon} \subset \text{Population et Individu} \in \begin{cases} \text{Echantillon} \\ \text{Population} \end{cases}$$

1.1.2 Caractère-Modalités

Tout aspect particulier ou caractéristique qui fait l'intérêt d'une série d'observations statistiques est appelé **caractère statistique** ou tout simplement **caractère**. Ainsi un caractère statistique est un attribut, un aspect particulier, une caractéristique spécifique ou encore une propriété particulière faisant l'objet d'une étude ou d'une observation répétée.

Exemple 1.3.

Couleur des yeux, opinion politique, mention à un examen, niveau de vie, taille, poids, nombre d'enfant par ménage, catégorie socio-professionnelle, budget publicitaire par catégorie d'entreprise d'une ville, etc.

Une valeur possible que peut prendre un caractère est appelée **une modalité** de ce caractère.

Exemple 1.4.

Rouge, Démocrate, Assez Bien, Moyen, 1m72, [80kg, 83kg], 1, Ouvrier, 1030085F ; sont des modalités respectives des caractères de l'exemple ci-dessus.

Nous noterons $\mathcal{M}$, l'ensemble des modalités (distinctes) prises par un caractère. Même si ce dernier est vaste, on le prend souvent fini. Selon la nature (topologique) de l'ensemble de ses modalités, on dit d'un caractère qu'il est :

- **qualitatif** : les modalités sont des libellés et donc ne sont pas naturellement quantifiables. Elles sont les différentes catégories d'une nomenclature. Ces catégories doivent être exhaustives (chaque individu est affecté à une modalité) et incompatibles (un individu ne peut être affecté à plusieurs modalités) de façon à créer une partition.

Exemple 1.5.

Couleur des yeux, Opinion politique, Mention à un examen, Niveau de vie, Catégorie socio-politique.

On distingue deux types de caractère qualitatif :

- ★ le caractère **qualitatif ordinal** : il existe un ordre naturel entre les modalités ;

Exemple 1.6.

Mention à un examen, Niveau de vie, Catégorie socio-professionnelle.

- ★ le caractère **qualitatif nominal** : les modalités ne peuvent être ordonnées naturellement.

Exemple 1.7. Couleur des yeux, Opinion politique.

- **quantitatif** : les modalités sont naturellement quantifiables et sont représentées par des nombres ou des ensembles de nombres (intervalles). Elles sont liées à l'unité choisie, qui doit être précisée.

On distingue également deux types de caractère quantitatif :

- ★ **discret** : l'ensemble des modalités est discret (composé d'éléments isolés).

Exemple 1.8.

Nombre d'enfants par ménage, Budget publicitaire des entreprises d'une ville, durée de vie d'un moustique,

★ **continu** : l'ensemble des modalités est continu (il n'y a pas de saut entre les modalités).

Exemple 1.9. masse des pommes issue d'une ferme, taille, longueur des ongles des patients.

1.1.3 Variable statistique

Définition 1.10.

Soit Ω une population concernée par une étude statistique et $\mathcal{M}$ l'ensemble des modalités du caractère étudié. Une variable statistique sur Ω est la donnée d'une application :

$$\begin{aligned} X : \Omega &\longrightarrow \mathcal{M} \\ \omega &\longmapsto X(\omega) = x \end{aligned}$$

qui associe à chaque individu ω de la population, sa modalité x pour le caractère observé.

Noter qu'une variable statistique est surjective par définition mais n'est pas toujours injective.

L'ensemble des individus prenant la modalité x est le pré-image du singleton $\{x\}$ par X noté $X^{-1}\{x\}$

Proposition 1.11.

Le cardinal de $\mathcal{M}$, le nombre de modalités distinctes prises par une variable statistique X , est appelé la **taille de la variable** X : $\text{card}(\mathcal{M}) = \text{taille}(X)$.

Remarque 1.12.

Dans la pratique, la taille d'une variable statistique est finie. On la notera k . Observons que les ensembles $X^{-1}\{x_i\}$ avec $i = 1, \dots, k$, forment une partition de Ω .

Propriété 1.13. (Typologie des variables statistiques)

En fonction du type de caractère étudié, une variable statistique peut être soit qualitative ordinaire ou nominale soit quantitative discrète ou continue.

1.2 Traitement numérique

1.2.1 Fréquences

Le nombre d'individus pour lesquels la variable statistique prend la modalité x_i est appelé **l'effectif partiel** ou la **fréquence absolue** de la modalité x_i et est souvent noté n_i :

$$n_i = \text{card}X^{-1}\{x_i\}.$$

En d'autres termes, le nombre de fois la modalité x_i est observée au sein de la série statistique représente sa fréquence absolue.

La somme des effectifs partiels pour toutes les différentes modalités donne l'effectif total de la population ; on a :

$$N = \sum_{i=1}^k n_i = \sum_{i=1}^k \text{card}X^{-1}\{x_i\} = \text{card}\Omega.$$

La **fréquence relative** de la modalité x_i est le quotient de la fréquence absolue (l'effectif partiel) n_i par la fréquence absolue totale (l'effectif total). On la note f_i et elle est souvent calculée en pourcentage :

$$f_i = \frac{n_i}{N} \text{ ou } f_i = \frac{n_i}{N} \times 100 \text{ } ^\circ/\text{o}.$$

On appelle **fréquence absolue cumulée croissante** (resp. **décroissante**) de la modalité x_i la somme de toutes les fréquences absolues des modalités inférieures ou égales à x_i (resp. supérieures ou égales à x_i). De la même manière, on définit la **fréquence relative cumulée croissante** (resp. **décroissante**) de la modalité x_i comme étant la somme de toutes les fréquences absolues des modalités inférieures ou égales à x_i (resp. supérieures à x_i).

Dans toute la suite, nous désignerons par N_i^{cc} (resp. N_i^{cd}) la fréquence absolue (effectif) cumulée croissante (resp. décroissante) et par F_i^{cc} (resp. F_i^{cd}) la fréquence relative cumulée croissante (resp. décroissante) de la modalité x_i . On définit ces quantités comme suit :

$$\begin{aligned} N_i^{cc} &= \sum_{j=1}^i n_j, & N_i^{cd} &= \sum_{j=i}^k n_j = N - N_{i-1}^{cc} \\ F_i^{cc} &= \sum_{j=1}^i f_j, & F_i^{cd} &= \sum_{j=i}^k f_j = 1 - F_{i-1}^{cc}. \end{aligned}$$

1.2.2 Tableaux statistiques

Tableau statistique associé à un caractère quantitatif discret

Valeurs observées x_i	Fréq. absolue n_i	Fréq. relative f_i ($^0/0$)	F_i^{cc}	F_i^{cd}
x_1	n_1	f_1	F_1^{cc}	F_1^{cd}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_p	n_p	f_p	F_p^{cc}	F_p^{cd}
Total	N	100	$\checkmark$	$\checkmark$

Tableau statistique associé à un caractère quantitatif continu

Classe $N^o i : [b_i; b_{i+1}[$	Centre des classes c_i	Fréq. absolue n_i	Fréq. relative f_i ($^0/0$)	F_i^{cc}	F_i^{cd}
$[b_1; b_2[$	c_1	n_1	f_1	F_1^{cc}	F_1^{cd}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[b_p; b_{p+1}[$	c_p	n_p	f_p	F_p^{cc}	F_p^{cd}
Total	$\checkmark$	N	100	$\checkmark$	$\checkmark$

1. Par convention, une classe est un intervalle fermé à gauche et ouvert à droite, du type $[b_i; b_{i+1}[$. La classe est dite bornée si $b_i \neq -\infty$ et $b_{i+1} \neq +\infty$.
2. L'effectif n_i de la classe $[b_i; b_{i+1}[$ est le nombre d'individus dont le caractère prend une valeur supérieure ou égale à b_i et strictement inférieure à b_{i+1} .
3. Le centre "une classe bornée $[b_i; b_{i+1}[$ est $ci = \frac{b_i + b_{i+1}}{2}$.
4. L'amplitude d'une classe bornée $[b_i; b_{i+1}[$ est $a_i = b_{i+1} - b_i$.
5. La densité d'une classe bornée $[b_i; b_{i+1}[$ est $d_i = \frac{n_i}{a_i}$.

On calcule les densités lorsque les classes sont d'amplitudes inégales (mais finies).

1.2.3 Plus petite modalité-Plus grande modalité-Etendue

En dehors des observations d'une variable qualitative nominale, toute variable statistique possède une plus petite valeur appelée plus petite modalité souvent notée x_{min} et une plus grande valeur appelée plus grande modalité notée x_{max} . La différence de la plus grande modalité à la plus petite modalité est appelée **étendue** ou **dynamique** de la

série et notée e :

$$\begin{aligned} e &= \text{étendue} = x_{\max} - x_{\min} \\ &= x_{k+1} - x_1 \text{ (variable quantitative discrète/qualitative ordinale)} \\ &= b_{k+1} - b_1 \text{ (variable quantitative continue).} \end{aligned}$$

Exemple 1.14. (Exercice)

On s'est intéressé au poids (en milligramme) d'un échantillon de 35 pommes de terre. On a observé les valeurs suivantes :

289	282	287	280	290	291	286
287	284	281	285	286	288	287
290	292	285	287	278	286	285
286	280	284	288	290	287	284
289	288	284	286	285	287	282

Etablir le tableau statistique associé à ce caractère puis déterminer l'étendue de cette série.

Exemple 1.15. (Exercice)

L'étude statistique d'une population a permis de regrouper les individus par classes de même amplitude dont les centres sont les suivants : 52, 60, 68, 76, 84, 92.

1. Quelle est l'amplitude de chacune des classes ?
2. Calculer la limite inférieure et la limite supérieure de chaque classe.

Exemple 1.16. (Exercice)

On considère l'ensemble des notes obtenues, lors d'un test noté sur 20, par 50 candidats :

10	8	3	12	13	9	12	9	12	11
11	11	8	5	13	14	14	6	12	16
7	11	10	10	2	15	12	10	1	14
11	7	8	10	13	9	13	9	7	13
11	19	9	4	10	8	9	6	7	14

1. Dépouiller ces données et présenter les résultats dans un tableau (on prendra les classes suivantes : $[0, 5[$; $[5, 7[$; $[7, 9[$; $[9, 11[$; $[11, 13[$; $[13, 15[$; $[15, 20[$)
2. Calculer les fréquences.
3. Calculer les fréquences cumulées.
4. Quelle est la proportion des candidats ayant une note
 - (a) inférieure à 9 ?
 - (b) supérieure ou égale à 13 ?
 - (c) comprise entre 5 et 13 ?
5. Quelle est la classe dont la densité est la plus forte et celle dont la densité est la plus faible ?

1.3 Traitements graphiques

1.3.1 Diagramme en bâtons (cas discret)

Un diagramme en bâtons est un graphique dans lequel l'axe des abscisses représente les différentes modalités du caractère discret, tandis que l'axe des ordonnées représente les effectifs. Pour chaque modalité, on trace un bâton d'une longueur proportionnelle aux effectifs correspondants.

1.3.2 Les histogrammes

On appelle histogramme la représentation graphique des effectifs d'une variable statistique obtenue en portant :

1. sur l'axe des abscisses les limites réelles des classes.
2. sur l'axe des ordonnées les effectifs correspondants.

On obtient une suite de rectangles dont les surfaces doivent être proportionnelles aux effectifs.

Cas des classes d'amplitudes égales

Quand les classes sont d'amplitudes égales, chaque rectangle a une superficie proportionnelle aux effectifs. On mesure donc en ordonnée une hauteur proportionnelle à l'effectif correspondant

Cas des classes d'amplitudes différentes

D'une manière générale, si une classe est d'amplitude n fois plus grande (respectivement plus petite) que celles des classes considérées comme unité, il faudra avant toute représentation graphique, diviser (respectivement multiplier) par n l'effectif de la classe en question. Ainsi si les classes sont d'amplitudes différentes, on met en ordonnées les hauteurs corrigées en lieu et place des effectifs. Si a_r est la plus petite amplitude alors on a :

$$h_i^c = \left(\frac{n_i}{a_i} \right) \times a_r$$

On peut aussi considérer les densités en lieu et place des hauteurs corrigées.

1.3.3 Polygone des fréquences ou des effectifs

Dans le cas où les classes sont d'amplitudes égales, il est obtenu en joignant les milieux des côtés supérieurs des rectangles de l'histogramme. On complète le polygone aux extrémités avec deux points d'ordonnées nulles et dont les abscisses sont les milieux des classes extrêmes fictives (avant la première classe et après la dernière classe).

Dans le cas des classes d'amplitudes différentes, on subdivise ces classes en classes d'amplitude égale à la plus petite des amplitudes (ou au PGCD des amplitudes des amplitudes si elles sont des entiers) avant de joindre les milieux des côtés supérieurs des rectangles.

Exemple 1.17. ..

Le tableau suivant donne la répartition en classes d'amplitude 5 des tailles en cm de 40 individus

Classes	[155; 160[	[160; 165[	[165; 170[	[170; 175[	[175; 180[	[180; 185[
Effectifs	3	8	10	10	7	2
Fréq. abs. cum. croissante N_i^{cc}						
Fréq. abs. cum. décroissante N_i^{cd}						

Etablir l'histogramme puis le polygone des effectifs de cette série statistique.

1.3.4 Polygone des fréquences cumulées (ou effectifs cumulés)

Nous savons calculer les effectifs et les fréquences cumulés. Cependant, le Tableau de l'Exemple 1.14 ne permet pas de répondre à une question de style : "combien de pommes de terre pèsent moins de 285g, plus de 288g, entre 280 et 284g" ? Ces résultats ne figurent pas dans ce tableau, d'où la nécessité de la construction d'un dernier graphique permettant de lire directement la réponse à ce genre de questions.

Polygone des fréquences cumulées (ou effectifs cumulés) croissantes

On porte en abscisse les limites des classes et en ordonnées les fréquences cumulées (ou effectifs cumulés) correspondantes. A chaque limite supérieure d'une classe, on fait correspondre sa fréquence cumulée (ou effectif cumulé). On joint tous les points pour obtenir un polygone.

Principe de lecture : Pour répondre à la question "combien de pommes de terre pèsent au plus 285g ?", on porte 285 en abscisse et on cherche l'ordonnée correspondant sur le polygone des effectifs cumulés (ou fréquences cumulées) croissants. Cette ordonnée donne le pourcentage (cas des fréquences cumulées croissantes) ou l'effectif (cas des effectifs cumulés croissants) de pommes de terre pesant au plus 285g.

Polygone des fréquences cumulées (ou effectifs cumulés) décroissantes C'est le même type de construction. On porte les effectifs ou fréquences cumulées décroissantes en ordonnées et les classes en abscisses. Principe de lecture : Pour répondre à la question "combien de pommes de terre pèsent au moins 288g ?", on porte 288 en abscisse et on cherche l'ordonnée correspondant sur le polygone des effectifs cumulés (ou fréquences cumulées) décroissants. Cette ordonnée donne le pourcentage (cas des fréquences cumulées décroissantes) ou l'effectif (cas des effectifs cumulés décroissants) de pommes de terre pesant au moins 288g.

Exercice 1.18. .

1. Tracer les polygones des fréquences absolues cumulées croissantes et décroissantes de l'Exemple 1.17.
2. Tracer les courbes des fréquences cumulées croissantes et décroissantes de l'Exemple 1.14.

Remarque 1.19. .

Dans le cas d'une distribution discrète l'histogramme devient un diagramme en bâtons et la courbe de fréquences cumulées (ou effectifs cumulés) est une fonction en escalier.

1.3.5 Fonction de répartition d'une variable statistique discrète

Pour une variable statistique discrète, les valeurs x_i des modalités sont des réels et on peut donc directement les comparer à n'importe quel réel. On écrit donc :

$$F : \mathbb{R} \longrightarrow [0; 1]$$

$$x \longmapsto F(x) = \begin{cases} 0 & \text{si } x < x_{\min} = x_1; \\ F_i^{cc} & \text{si } x_i \leq x < x_{i+1} \text{ pour tout } 1 \leq i \leq k-1; \\ 1 & \text{si } x \geq x_{\max} = x_k. \end{cases}$$

1.3.6 Fonction de répartition d'une variable continue

Pour une variable statistique continue, les valeurs x_i des modalités sont des classes de réels et on ne peut donc directement les comparer à un réel. Ainsi a priori, la fonction de répartition d'une variable continue ne sera connue que pour les extrémités de classes : les bornes des classes.

Cependant, si l'on admet l'hypothèse de répartition uniforme des observations au sein de chaque classe, on peut estimer les valeurs de $F(x)$ par interpolation linéaire. Cela revient à approximer la représentation graphique par une fonction affine par morceaux : concrètement, on trace la courbe en joignant deux points consécutifs connus par un segment de droite (cette courbe est aussi appelée ogive de Galton). Avec cette hypothèse, $F(x)$ représente l'aire située sous l'histogramme des fréquences (relatives), à gauche de la valeur x .

Propriété 1.20.

Soit X une variable statistique et F sa fonction de répartition. On a :

- $\forall x \in \mathbb{R}, 0 \leq F(x) \leq 1$;
- F est croissante sur $\mathbb{R}$ et continue à gauche en chacun de ses points de discontinuité ;
- $\lim_{x \rightarrow -\infty} F(x) = 0$ et $\lim_{x \rightarrow +\infty} F(x) = 1$.

Proposition 1.21.

Toute fonction F définie de $\mathbb{R}$ vers $[0; 1]$ et possédant les propriétés ci-dessus est la fonction de répartition d'une variable statistique réelle.

1.4 Caractéristique de position et de dispersion


1.4.1 Le mode et la classe modale

Soit une série statistique présentant un regroupement en classes.

1. Dans le cas où les classes sont de même amplitude, on appelle classe modale de cette série toute classe d'effectif (ou de fréquence) maximal(e). On note souvent le mode M_0 .
2. Lorsque les classes sont d'amplitudes différentes, la classe modale est la classe ayant la plus grande densité.

Un mode peut être obtenu par une construction graphique (à partir de l'histogramme des fréquences) ou par un calcul direct en supposant une distribution uniforme au sein des classes.

En effet, soit $x_i = [b_i, b_{i+1}[$ une classe modale; ainsi $x_{i-1} = [b_{i-1}, b_i[$ est la classe avant la classe modale et $x_{i+1} = [b_{i+1}, b_{i+2}[$ celle venant après la classe modale. Désignons par h_i^c et par h_{i-1}^c (resp. h_{i+1}^c) la hauteur corrigée de la classe modale et celle de la classe venant avant (resp. après) la classe modale. Considérons les points $A = (b_i, h_i^c)$, $C = (b_{i+1}, h_{i+1}^c)$, $D = (b_i, h_{i-1}^c)$ et $B = (b_{i+1}, h_i^c)$ sur l'histogramme des fréquences.



Le mode M_0 est l'abscisse b du point de coordonnées (b, h) situé à l'intersection des segments $[AC]$ et $[DB]$ obtenus en joignant les points A et C d'une part et D et B d'autre part; $[AC]$ et $[DB]$ sont les diagonales du quadrilatère $ABCD$ qui est souvent un trapèze rectangle de hauteur $AB = a_i$ (l'amplitude de la classe modale).

Numériquement, les coordonnées (b, h^c) du point situé à l'intersection des segments $[AC]$ et $[DB]$ sont obtenues en résolvant le système d'équations suivant :

$$\begin{cases} b - b_i = \frac{b_{i+1} - b_i}{h_{i+1}^c - h_i^c} (h^c - h_i^c) & \text{équation cartésienne de la droite (AC)} \\ b - b_i = \frac{b_{i+1} - b_i}{h_i^c - h_{i-1}^c} (h^c - h_{i-1}^c) & \text{équation cartésienne de la droite (DB)} \end{cases}$$

Le mode M_0 , abscisse de ce point est donné par :

$$M_0 = b_i + a_i \frac{\Delta_{\text{inf}}}{\Delta_{\text{sup}} + \Delta_{\text{inf}}} \text{ où } \Delta_{\text{inf}} = h_i^c - h_{i-1}^c \text{ et } \Delta_{\text{sup}} = h_i^c - h_{i+1}^c.$$

En particulier, si les classes sont de même amplitude a , le mode M_0 est donnée par :

$$M_0 = b_i + a_i \frac{n_i - n_{i-1}}{2n_i - (n_{i-1} + n_{i+1})} \text{ où on a utilisé } \Delta_{\text{inf}} = n_i - n_{i-1} \text{ et } \Delta_{\text{sup}} = n_i - n_{i+1}.$$

Remarque 1.22. .

1. Dans une série statistique, on peut avoir plusieurs classes modales et donc plusieurs modes.
2. Dans le cas d'une variable statistique discrète, le mode s'observe directement : c'est la modalité ayant le plus grand effectif ou la plus grande fréquence.

1.4.2 La médiane-La classe médiane

La **médiane** d'une distribution statistique de taille N d'une variable statistique X est la valeur de la variable X (ou valeur susceptible d'être prise par la variable X), souvent notée M_e , telle que le nombre d'individus de modalités supérieures ou égales à M_e et le nombre d'individus de modalités strictement inférieures à M_e soient tous deux égaux à $\frac{N}{2}$. En d'autres termes, c'est la valeur de la variable qui subdivise la distribution statistique en deux sous distributions de même effectif égal à la moitié de l'effectif totale. Elle ne peut se calculer pour une variable qualitative nominale.

1. Dans le cas d'une variable discrète, du point de vue d'une distribution individualisée (on ne regroupe pas les modalités même si elles sont répétées), c'est la modalité de profondeur $\frac{N+1}{2}$. En effet :

- (a) Si N est impair alors $N+1$ est pair et la modalité $x_{\frac{N+1}{2}}$ divise la distribution en deux sous-distribution de même effectif $\frac{N}{2}$

$$x_1 < \cdots < x_{\frac{N+1}{2}-1} < x_{\frac{N+1}{2}} < x_{\frac{N+1}{2}+1} < \cdots < x_N.$$

- (b) Si N est pair distribution individualisée $x_1 < \cdots < x_{\frac{N}{2}-1} < x_{\frac{N}{2}} < x_{\frac{N}{2}+1} < \cdots < x_N$ alors la médiane se trouverait entre les modalités $x_{\frac{N}{2}}$ et $x_{\frac{N}{2}+1}$. Ainsi, n'importe quelle valeur centrale de cet intervalle, parfois appelé intervalle médian, est candidat pour être la médiane.

Généralement, on choisit $M_e = \frac{x_{\frac{N}{2}} + x_{\frac{N}{2}+1}}{2}$.

2. Dans le cas d'une variable continue où les observations sont regroupées en classe $(x_i)_{1 \leq i \leq k}$, une classe $x_i = [b_i, b_{i+1}[$ telle que $N_{i-1}^{cc} < \frac{N}{2}$ et $N_i^{cc} > \frac{N}{2}$ ($F(b_i) < 0,5$ et $F(b_{i+1}) > 0,5$) où F est la fonction de répartition de la variable X) est appelée la classe médiane. En supposant une répartition uniforme au sein des classes on utilise la technique de l'interpolation pour trouver la médiane par la formule :

$$M_e = b_i + a_i \left(\frac{\frac{N}{2} - N_{i-1}^{cc}}{n_i} \right) = b_i + a_i \left(\frac{\frac{1}{2} - F_{i-1}^{cc}}{f_i} \right)$$

où $a_i = b_{i+1} - b_i$ (amplitude de la classe médiane) et N_{i-1}^{cc} (resp. F_{i-1}^{cc}) est la fréquence absolue (resp. relative) cumulée croissante de la classe x_{i-1} .

Remarque 1.23. .

En pratique la détermination de la médiane se fait à l'aide des polygones des fréquences relatives cumulées croissantes ou décroissantes. C'est l'abscisse du point de ces polygones qui a pour ordonnées 50% .

On peut aussi déterminer la médiane à l'aide des polygones des fréquences absolues cumulées croissantes ou décroissantes. Dans ce cas, c'est l'abscisse du point de ces polygones qui a pour ordonnée $\frac{N}{2}$.

La médiane est l'abscisse du point d'intersection des polygones des fréquences cumulés croissants ou décroissants.

1.4.3 La moyenne arithmétique

Soit $([a_i; a_{i+1}[)_{1 \leq i \leq p}$ une série statistique présentant un regroupement en classes. On appelle moyenne de cette série la moyenne $\bar{X}$ de la série $(c_i; n_i)_{1 \leq i \leq p}$, où c_i représente le centre de la classe $[a_i; a_{i+1}[$ et n_i l'effectif de cette classe.

$$\bar{X} = \frac{1}{N} \sum_{i=1}^p n_i c_i.$$

Dans le cas où la variable est discrète : $(x_i; n_i)_{1 \leq i \leq p}$ on a :

$$\bar{X} = \frac{1}{N} \sum_{i=1}^p n_i x_i.$$

Propriétés de la moyenne arithmétique

1. Soient X une variable statistique, a et b des constantes réelles. Si on définit une nouvelle variable statistique $Z = aX + b$, alors $\bar{Z} = a\bar{X} + b$.
2. D'une manière générale si $Z = aX + bY$ alors $\bar{Z} = a\bar{X} + b\bar{Y}$.

1.4.4 Les autres moyennes

On se contentera de retenir leur définition. Soit $(n_i; x_i)_{1 \leq i \leq p}$ une série statistique et N son effectif total.

La moyenne harmonique

La moyenne harmonique d'une distribution statistique pour une variable statistique X est égale à l'inverse de la moyenne arithmétique des inverses des valeurs de cette variable. Si $\bar{X}_H$ désigne cette moyenne harmonique, on a :

$$\bar{X}_H = \frac{N}{\sum_{i=1}^p \frac{n_i}{x_i}}$$

La moyenne géométrique

On la note $\bar{X}_G$ et on la définit de la manière suivante :

$$\bar{X}_G = \sqrt[N]{x_1^{n_1} \cdot x_2^{n_2} \dots x_p^{n_p}} = (x_1^{n_1} \cdot x_2^{n_2} \dots x_p^{n_p})^{\frac{1}{N}}$$

La moyenne quadratique

La moyenne quadratique est égale à la racine carrée de la moyenne arithmétique des carrés des valeurs de cette série statistique. On la note $\bar{X}_Q$. On a :

$$\bar{X}_Q = \sqrt{\frac{1}{N} \sum_{i=1}^p n_i x_i^2}$$

On a la suite d'inégalités suivante liant toutes ces moyennes :

$$\bar{X}_H \leq \bar{X}_G \leq \bar{X} \leq \bar{X}_Q$$

1.4.5 Les quantiles

Les quantiles constituent une généralisation de la notion de médiane. Soit $\alpha \in [0; 1]$. On appelle quantile d'ordre α , le nombre noté X_α (ou la valeur théorique susceptible d'être prise par la variable) qui divise la distribution en deux parties de proportions α et $1 - \alpha$. Puisqu'il s'agit d'adaptation de définition à une fonction discontinue, on rencontre dans la littérature quelques définitions selon que l'on fasse une interpolation linéaire ou non. Notons cependant que ces définitions sont plus aisées avec une variable continue qu'une variable discrète et conduisent donc aux valeurs de quantiles qui peuvent être différentes d'une formule à une autre ; d'où les différences qu'on peut noter avec l'utilisation d'un ou l'autre logiciel de calcul statistique.

L'une des définitions dans la littérature qui retient notre attention, à cause de sa simplicité mais sûrement doit avoir une grande marge d'erreur, est la suivante :

- Si $N\alpha$ est un nombre entier alors $x_\alpha = \frac{1}{2}(x_{N\alpha} + x_{N\alpha+1})$
- Si $N\alpha$ n'est pas un nombre entier alors $x_\alpha = x_{E(N\alpha)+1}$ où $E(N\alpha)$ est la partie entière de $N\alpha$.

La détermination des quantiles n'est donc pas standardisée, on adopte ici le même principe de détermination que celui de la médiane décrit plus haut. Compte tenu peut être des raisons de leur importance, certains quantiles sont d'une utilisation fréquente : les quartiles, les déciles et les centiles.

• Les quartiles

Un quartile est l'une quelconque des trois modalités (mesurée ou théorique) qui divisent une distribution statistiques (données statistiques triées et classées en ordre croissant) en 4 parties égales de sorte que chaque partie représente $\frac{1}{4}$ de la distribution. Ce sont trois valeurs Q_1 ; Q_2 et Q_3 telles que :

- Q_1 , le **premier quartile**, correspond à un effectif cumulé croissant de 25 % du total. C'est la valeur de la variable telle que 25 % des observations soient inférieures.
- Q_2 , le **deuxième quartile**, correspond à un effectif cumulé croissant de 50 % du total. Q_2 est la **médiane** M_e .
- Q_3 **troisième quartile**, correspond à un effectif cumulé croissant de 75 % du total.

Ainsi pour une variable continue, sous les mêmes hypothèses comme dans la détermination de la médiane, le $m^{\text{ième}}$ quartile pour $m = 1, 2, 3$ est donné par :

$$Q_m = b_i + a_i \left(\frac{\frac{Nm}{4} - N_{i-1}^{cc}}{n_i} \right) = b_i + a_i \left(\frac{\frac{m}{4} - F_{i-1}^{cc}}{f_i} \right)$$

où $a_i = b_{i+1} - b_i$ (amplitude de la classe x_i contenant Q_m) et N_{i-1}^{cc} (resp. F_{i-1}^{cc}) est la fréquence absolue (resp. relative) cumulée croissante de la classe x_{i-1} .

• Les **déciles** : Ce sont 9 valeurs de la variable qui permettent de scinder la population en 10 parties de même effectif. Le premier décile D_1 est la valeur de la variable correspondant à un effectif cumulé croissant de 10 % ; le cinquième décile est en fait la médiane : $D_5 = Q_2 = M_e$.

Ainsi pour une variable continue, sous les mêmes hypothèses comme dans la détermination de la médiane, le $m^{\text{ième}}$ décile pour $m = 1, 2, 3, 4, 5, 6, 7, 8, 9$ est donné par :

$$D_m = b_i + a_i \left(\frac{\frac{Nm}{10} - N_{i-1}^{cc}}{n_i} \right) = b_i + a_i \left(\frac{\frac{m}{10} - F_{i-1}^{cc}}{f_i} \right)$$

où $a_i = b_{i+1} - b_i$ (amplitude de la classe x_i contenant D_m) et N_{i-1}^{cc} (resp. F_{i-1}^{cc}) est la fréquence absolue (resp. relative) cumulée croissante de la classe x_{i-1} .

• Les **centiles** : Ce sont 99 valeurs de la variable qui permettent de scinder la population en cent parties de même effectif. Le premier centile C_1 est la valeur de la variable correspondant à un effectif cumulé croissant de 1 %. Le **cinquantième** centile C_{50} est en fait la médiane.

Ainsi pour une variable continue, sous les mêmes hypothèses comme dans la détermination de la médiane, le $m^{\text{ième}}$ quartile pour $m = 1, 2, 3, 4, \dots$ est donné par :

$$C_m = b_i + a_i \left(\frac{\frac{Nm}{100} - N_{i-1}^{cc}}{n_i} \right) = b_i + a_i \left(\frac{\frac{m}{100} - F_{i-1}^{cc}}{f_i} \right)$$

où $a_i = b_{i+1} - b_i$ (amplitude de la classe x_i contenant C_m) et N_{i-1}^{cc} (resp. F_{i-1}^{cc}) est la fréquence absolue (resp. relative) cumulée croissante de la classe x_{i-1} .

1.4.6 Les caractéristiques de dispersion

La variance, l'écart-type et l'écart-moyen

Soit $([a_i; a_{i+1}[; n_i])_{1 \leq i \leq p}$ une série statistique d'effectif total N et de moyenne $\bar{X}$. On désigne par c_i le centre de la classe $[a_i; a_{i+1}[$.

• L'écart-moyen est le nombre réel noté e_m tel que :

$$e_m = \frac{1}{N} \sum_{i=1}^p n_i |c_i - \bar{X}|$$

• La variance est le nombre réel positif noté $V(X)$ tel que :

$$V(X) = \frac{1}{N} \sum_{i=1}^p n_i (c_i - \bar{X})^2 = \frac{1}{N} \sum_{i=1}^p n_i c_i^2 - \bar{X}^2$$

La variance possède les propriétés suivantes :

Propriétés 1.24. .

1. La variance s'exprime dans une unité égale au carré de celle qui sert à exprimer la variable statistique.
2. Si on définit une nouvelle variable statistique $Y = X + b$, où b est une constante réelle, alors on a : $V(Y) = V(X)$.
3. Si on définit la variable Y par $Y = aX$, où a est une constante réelle, on a : $V(Y) = a^2 V(X)$.

- l'écart-type est un indicateur de dispersion. Il est défini comme étant la racine carrée de la variance. On la note σ_X . On a alors

$$\sigma(X) = \sqrt{V(X)}$$

Remarque 1.25. .

On peut déduire une écriture plus simple de la moyenne quadratique :

$$\bar{X}_Q = \sqrt{\frac{1}{N} \sum_{i=1}^p n_i c_i^2} = \sqrt{V(X) + \bar{X}^2}$$

Intervalle inter-quantiles - Ecart inter-quantiles - Ecart inter-quantiles relatifs

Dans une distribution d'une variable statistique, l'ensemble des modalités comprises entre le premier quantile et le dernier quantile de la même catégorie détermine **l'intervalle inter-quantile** ; c'est l'intervalle fermée bornée de borne inférieure le premier quantile et de borne supérieure le dernier quantile de la catégorie. Il contient une certaine proportion bien précise des observations. L'amplitude de cet intervalle, de même unité que les modalités, est appelée **écart inter-quantile**. Le rapport écart inter-quantile à la médiane est un nombre adimensionné appelé **écart inter-quantile relatif**. Le tableau suivant récapitule ces informations pour les quantiles fréquemment utilisés.

Quantiles X	Quartiles	Déciles	Centiles
Intervalle inter-quantile	inter-quartile : $[Q_1, Q_3]$	inter-décile : $[D_1, D_9]$	inter-centile : $[C_1, C_{99}]$
Écart inter-quantile	$Q_3 - Q_1$	$D_9 - D_1$	$C_{99} - C_1$
Écart inter-quantile relatif	$\frac{Q_3 - Q_1}{M_e}$	$\frac{D_9 - D_1}{M_e}$	$\frac{C_{99} - C_1}{M_e}$
Proportion contenue	$50\text{ }^\circ/o$	$80\text{ }^\circ/o$	$98\text{ }^\circ/o$

Les moments et les moments centrés

- Moments d'ordre r . On appelle ainsi les nombres réels notés $m_r(X)$ et définis par :

$$m_r(X) = \frac{1}{N} \sum_{i=1}^p n_i x_i^r$$

- Moments centrés d'ordre r . Ce sont les nombres réels notés μ_r et définis par :

$$\mu_r(X) = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{X})^r$$

Remarque 1.26. .

D'une manière générale, les moments centrés d'ordre pair renseignent sur la dispersion des observations autour de la moyenne $\bar{X}$. Par contre les moments d'ordre impair renseignent sur la dissymétrie de la distribution.

Coefficient de dispersion ou coefficient de variation Le coefficient de dispersion, comme l'intervalle interquantile relatif, est un indicateur de dispersion relatif qui permet d'éliminer les deux inconvénients majeurs de l'écart-type. On le note C_V et il est égal au rapport de l'écart-type sur la moyenne arithmétique.

$$C_V = \frac{\sigma(X)}{\bar{X}}$$

C'est un nombre sans unité, permettant de comparer les dispersions de toutes les distributions quelles que soient leurs unités et les valeurs de la variable.

1.4.7 Paramètres de forme

Coefficient d'asymétrie de Fisher

C'est le nombre réel noté γ_2 et défini par :

$$\gamma_2 = \frac{\mu_3(X)}{[\sigma(X)]^3} = \frac{\mu_3(X)}{[\mu_2(X)]^{\frac{3}{2}}}$$

Coefficient d'asymétrie de Pearson

C'est le nombre réel noté γ_3 et défini par :

$$\gamma_3 = \frac{\overline{X} - M_0}{\sigma(X)}.$$

Remarque 1.27.

Pour tout $\gamma \in \{\gamma_2, \gamma_3\}$, on a :

1. si $\gamma < 0$, la distribution est étalée vers la gauche (**biais négatif**).
2. si $\gamma > 0$, la distribution est étalée vers la droite (**biais positif**).
3. si $\gamma = 0$, la distribution est **symétrique**.

Coefficient d'aplatissement de Pearson

C'est le nombre réel noté β et défini par :

$$\beta = \frac{\mu_4(X)}{[\sigma(X)]^4} = \frac{\mu_4(X)}{[\mu_2(X)]^2}$$

1. Si $\beta = 3$, la distribution est "**normale**" (courbe en cloche de Gauss).
2. Si $\beta < 3$, la distribution est **plus aplatie** que la distribution normale (**hyponormale ou Platykurtique**).
3. Si $\beta > 3$, la distribution est **moins aplatie** que la distribution normale (**Hypernormale ou Leptokurtique**).

Ces deux coefficients (γ et α) sont sans dimension et indépendants d'un changement d'échelle ou d'origine.

Remarque 1.28. .

L'étendue d'une série est la différence entre la plus grande valeur observée dans la série et la plus petite valeur.

$$\text{étendue} = x_{\max} - x_{\min}$$

1.5 Quelques exercices

Exercice 1.29. .

Pour chaque question, choisir la (les) lettre(s) correspondante(s) à la (aux) bonne(s) réponse(s).

1. En statistique, on peut avoir un caractère qualitatif :
 (a) communal (b) honorable (c) nominal (d) continu
 (e) départemental (f) cardinal (g) discret (h) ordinal
2. En statistique, on peut avoir un caractère quantitatif :
 (a) continu (b) national (c) nominal (d) discret
 (e) ordinal (f) étudiant (g) international (h) professeur
3. La notation $\sum_{i=1}^{10} i^2$ est égale à :
 (a) $1 + 1^2 + \dots + 1^{10}$ (b) $1 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2 + 7^2 + 9^2 + 10^2$
 (c) $1 + 2^2 + \dots + 10^{10}$ (d) $(1 + 2 + \dots + 10) + (1 + 2 + \dots + 10)$
 (e) $1 + 2^2 + \dots + 10^2$ (f) $10 + 10^2 + \dots + 10^2$
4. La moyenne arithmétique d'une variable quantitative discrète (avec les notations standard) est :

$$\begin{array}{lll} (a) \sum_{i=1}^k n_i x_i & (b) \frac{n_1 x_1 + n_2 x_2 + \dots + n_k x_k}{N} & (c) \frac{n_1 f_1 + n_2 f_2 + \dots + n_k f_k}{N} \\ (d) \sum_{i=1}^k f_i x_i & (e) \frac{n_1 x_1^2 + n_2 x_2^2 + \dots + n_k x_k^2}{N} & (f) \frac{n_1^2 f_1 + n_2^2 f_2 + \dots + n_k^2 f_k}{N} \end{array}$$

5. La variance d'une variable quantitative discrète (avec les notations standard) est :

$$(a) \left(\sum_{i=1}^k n_i x_i^2 \right) - \bar{x}^2$$

$$(b) \frac{n_1 x_1^2 + n_2 x_2^2 + \dots + n_k x_k^2 - \bar{x}^2}{N}$$

$$(c) \frac{(n_1 f_1 + n_2 f_2 + \dots + n_k f_k)^2}{N}$$

$$(d) \sum_{i=1}^k f_i (x_i - \bar{x})$$

$$(e) \frac{n_1 x_1^2 + n_2 x_2^2 + \dots + n_k x_k^2}{N} - \bar{x}^2$$

$$(f) \frac{n_1^2 f_1 + n_2^2 f_2 + \dots + n_k^2 f_k}{N} - \bar{x}^2$$

Exercice 1.30. .

Un professeur d'éducation physique a fait passer une épreuve de saut en longueur à deux classes d'effectifs respectifs $n_1 = 30$ et $n_2 = 40$. La classe n°1 obtient une moyenne $m_1 = 4,50m$ et la classe n°2 une moyenne $m_2 = 4,65m$.

Quelle est alors la moyenne m obtenue par le nouvel échantillon constitué par l'ensemble des deux classes ?

Exercice 1.31. .

Après correction des copies, la moyenne à l'épreuve de mathématiques au baccalauréat est $x = 8,4$.

1. Si le ministre de l'Education Nationale décide d'augmenter la note de chaque copie de 1,6 point, quelle sera la nouvelle moyenne nationale ?
2. Si le ministre de l'Education Nationale décide d'augmenter la note de chaque copie de 10 %, quelle sera la nouvelle moyenne nationale ?

Exercice 1.32. .

Une étude sur le budget consacré aux vacances d'été auprès de ménages a donné les résultats suivants :

Budget X	Fréquence cumulée croissante	Fréquence
$[800, 1000[$	0,08	
$[1000, 1400[$	0,18	
$[1400, 1600[$	0,34	
$[1600, b[$	0,64	
$[b, 2400[$	0,73	
$[2400, a[$	1	

1. Calculer la borne manquante a sachant que l'étendue de la série est égale à 3200.
2. Calculer les fréquences dans le tableau.
3. Calculer la borne manquante b dans les deux cas suivants :
 - (a) Le budget moyen est égal à 1995.
 - (b) Le budget médian est égal à 1920.

Exercice 1.33. .

Les moyennes des notes obtenues par les 50 candidats à un concours se répartissent comme suit :

Classe	$[0; 4[$	$[4; 8[$	$[8; 12[$	$[12; 16[$	$[16; 20[$
Effectif	5	14	20	7	4

1. Dresser le tableau des fréquences absolues cumulées croissantes et décroissantes, puis construire les polygones des fréquences cumulées croissantes et décroissantes.
2.
 - (a) Calculer le mode et la médiane de cette série statistique.
 - (b) Calculer la moyenne $\bar{x}$ de cette série statistique.
 - (c) Que peut-on dire de la forme de la distribution ?
3. Déterminer la moyenne des notes obtenues par l'élève qui s'est classé quinzième au concours, puis celle de l'élève qui s'est classé dixième.

Exercice 1.34.

Dans un sous-groupe de 40 personnes la taille moyenne est de 170 cm.

Dans un deuxième sous-groupe de 10 personnes la taille moyenne est de 180 cm.

Dans un troisième sous-groupe de 50 personnes la taille moyenne est de 175 cm.

1. Déterminer la taille moyenne du groupe constitué par les trois sous-groupes précédents.
2. Quelle serait la taille moyenne si les trois sous-groupes étaient constitués du même nombre de personnes ?

Exercice 1.35.

La température est relevée chaque heure pendant 4 jours dans une forêt. Les 97 résultats obtenus ont été triés et sont rassemblés dans le tableau suivant

Température	14,5	15	15,5	16	16,5	17	17,5	18	18,5	19	19,5
Nombre de fois où cette température a été relevée	5	7	10	12	15	10	11	9	7	7	4

1. Déterminer la médiane M_e , les quartiles Q_1 et Q_3 puis les déciles D_1 et D_9 de cette série statistique.
2. Calculer la moyenne arithmétique de cette série statistique.

Exercice 1.36.

Le tableau ci-dessous donne la répartition des salaires mensuels, en euros, des employés d'une entreprise :

Classe	[800; 900[	[900; 1000[	[1000; 1050[	[1050; 1150[	[1150; 1300[
Effectif	42	49	74	19	16

1. Calculer le salaire moyen dans cette entreprise.
2. Dans cette entreprise, combien d'employés gagnent au moins 1050 euros ?
3. Calculer de manière précise la médiane et les quartiles Q_1 et Q_3 puis les déciles D_1 et D_9 de cette série statistique.

Exercice 1.37.

Un relevé des durées des communications téléphoniques effectués dans un central téléphonique a fourni les informations consignées dans le tableau suivant (l'unité de durée est la minute)

Intervalle de durée	[0; 2[	[2; 4[	[4; 6[	[6; 8[	[8; 10[	[10; 12[
Effectif	14	16	25	15	17	13

1. Calculer la durée moyenne d'un appel
2. On regroupe les classes par deux, ce qui revient à considérer les classes $[0; 4[$, $[4; 8[$ et $[8; 12[$. Calculer la durée moyenne d'un appel pour cette nouvelle série.
3. Quelle conclusion pouvez-vous formuler ?

Exercice 1.38.

Une entreprise de services à domicile en plomberie et électricité a établi le relevé suivant de ses interventions journalières pour une période de 52 jours ouvrables.

Nombre d'interventions	14	15	16	17	18	19	20	21	22	23	24	25
Nombre de jours	1	2	4	4	5	7	8	7	6	5	2	1

Déterminer la médiane et les quartiles Q_1 et Q_3 .

STATISTIQUE BIVARIÉE

Quand l'étude statistique d'un phénomène porte sur la manifestation simultanée de deux aspects particuliers du phénomène, on parle de **statistique à deux caractères** ou encore **statistique à deux variables**. Les données collectées dans ce cas sont appelées série statistique à deux variables ou tout simplement série double. Ainsi, le statisticien définit et s'intéresse alors à l'étude simultanée de deux variables statistiques, disons X et Y , observées sur le même échantillon (le même ensemble d'individus). On dit que la paire (X, Y) est un couple de variables statistiques. L'objectif essentiel des méthodes présentées dans ce chapitre est de chercher à mettre en évidence une éventuelle relation entre les variations simultanées des deux variables X et Y , qu'on appellera alors liaison entre X et Y . En effet, l'un des objectifs fondamentaux de la statistique est de mettre en évidence des liaisons entre des variables statistiques ; ces liaisons servant à exprimer d'éventuelles relations entre les phénomènes représentés par ces variables, dans le but principal d'une prévision. Par exemple, dans un groupe d'hommes adultes, on peut penser qu'il existe une relation entre la taille et le poids, mais une étude statistique simultanée de ces deux caractères permettrait d'infirmier ou de confirmer cette pensée.

Dans certains cas, une liaison peut être considérée à priori comme causale, une variable expliquant l'autre (c'est le cas dans l'exemple ci-dessus, puisqu'on peut penser que la taille explique, au moins partiellement, le poids) ; dans d'autres cas, ce n'est pas pareil et les deux variables jouent alors des rôles symétriques. Dans la pratique, il conviendra de bien différencier les deux situations. Pour étudier la liaison entre deux variables, nous allons introduire d'une part des graphiques spécifiques et d'autre part des caractéristiques numériques exprimant cette liaison.

2.1 Introduction

On a relevé le poids (en kg) et la taille (en cm) de 30 personnes. Les résultats suivants ont été obtenus :

Poids(X)	65	68	62	62	68	68	59	71	74	68	68	71	71	65	65
Taille(Y)	165	177	174	168	165	171	165	177	174	171	165	174	174	174	171
Poids(X)	62	65	68	71	65	74	74	71	65	77	74	62	77	68	71
Taille(Y)	174	174	171	171	174	168	177	174	165	180	177	168	180	171	174

Ces données permettent de définir deux séries statistiques à un caractère $(x_i; n_i)$ et $(y_j; n_j)$ représentées par les deux tableaux :

x_i	59	62	65	68	71	74	77
n_i	1	4	6	7	6	4	2

y_j	165	168	171	174	177	180
n_j	5	3	6	10	4	2

A chaque couple $(x_i; y_j)$, on associe le nombre de personnes ayant le poids x_i et la taille y_j . Ce nombre est noté n_{ij} .

On définit ainsi une série statistique à deux caractères; n_{ij} est appelée effectif de la modalité $(x_i; y_j)$. La série à deux caractères x_i et y_j , notée $(x_i; y_j; n_{ij})$ est représentée par le tableau à double entrée ci-dessous :

$y_j \backslash x_i$	59	62	65	68	71	74	77	Total
165	1	0	2	2	0	0	0	5
168	0	2	0	0	0	1	0	3
171	0	0	1	4	1	0	0	6
174	0	2	3	0	4	1	0	10
177	0	0	0	1	1	2	0	4
180	0	0	0	0	0	0	2	2
Total	1	4	6	7	6	4	2	30

2.2 Nuage de point associé à une série double

Soit $(x_i; y_j; n_{ij})$ une série statistique à deux caractères quantitatifs. L'ensemble des points $M_{ij}(x_i; y_j)$ est appelé nuage de points associés à la série. Ce nuage est représenté de deux façons :

2.2.1 Représentation par points pondérés

On indique à côté de chaque point M_{ij} l'effectif n_{ij} .

2.2.2 Représentation par tâches

Chaque point M_{ij} est remplacé par un disque dont l'aire est proportionnelle à n_{ij} .

2.3 Point moyen

Définition 2.1. .

Soit $(x_i; y_j; n_{ij})$ une série statistique à deux caractères quantitatifs.

On appelle **point moyen** du nuage de points représentant cette série le point de coordonnées $(\bar{X}; \bar{Y})$ où $\bar{X}$ et $\bar{Y}$ désignent les moyennes respectives des séries marginales $(x_i; n_i)$ et $(y_j; n_j)$.

Exemple 2.2. .

Dans l'exemple de l'Introduction, vérifier que le point moyen G a pour coordonnées $X_G = 68,3$ et $Y_G = 172,1$.

Exemple 2.3. .

Les notes obtenues par 10 élèves aux épreuves de SVT et de Sciences Physiques (SP) lors d'un examen sont indiquées comme suit :

SVT(x)	9	12	5	6	9	14	3	6	12	14
SP(y)	10	13	8	10	13	17	5	8	16	16

1. Représenter le nuage de points associé à cette série. (On fera la représentation par pondération)
2. Déterminer son point moyen.

2.4 Ajustement linéaire : Méthode des moindres carrées

2.4.1 Covariance

Soit $(x_i; y_j; n_{ij})_{1 \leq i \leq n; 1 \leq j \leq m}$ une série statistique à deux caractères X et Y , d'effectif total N . La **covariance** de cette série est le nombre réel noté $Cov(X; Y)$ tel que :

$$\begin{aligned} Cov(X; Y) &= \frac{1}{N} \sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y}) \\ &= \left(\frac{1}{N} \sum_{i=1}^N x_i y_i \right) - \bar{X} \cdot \bar{Y} \text{ Formule de Koenig} \end{aligned}$$

On utilise aussi la formule suivante pour calculer la covariance :

$$\begin{aligned} Cov(X; Y) &= \frac{1}{N} \sum_{i=1}^n \sum_{j=1}^m n_{ij} (x_i - \bar{X})(y_j - \bar{Y}) \\ &= \left(\frac{1}{N} \sum_{i=1}^n \sum_{j=1}^m n_{ij} x_i y_j \right) - \bar{X} \cdot \bar{Y} \text{ Formule de Koenig} \end{aligned}$$

2.4.2 Coefficient de corrélation

Soit $(x_i; y_j; n_{ij})$ une série statistique à deux caractères X et Y telles que $V(X) \neq 0$ et $V(Y) \neq 0$. Le **coefficient de corrélation linéaire** de cette série est le nombre réel noté r tel que

$$r = \frac{Cov(X; Y)}{\sqrt{V(X)V(Y)}}.$$

Propriétés 2.4. .

1. $-1 \leq r \leq 1$ c'est-à-dire $|r| \leq 1$.
2. Si $|r| = 1$ alors tous les points du nuage sont alignés. L'ajustement est dit **parfait** (les résultats sont fiables).
3. Si $0,87 \leq |r| \leq 1$, on dit qu'il y a une **forte corrélation** entre les variables X et Y (l'ajustement se justifie).
4. Si $|r|$ est très voisin de 0 alors il y a **indépendance linéaire** statistique.
5. Si $0,5 < |r| < 0,87$, la **corrélation est mauvaise**.
6. La corrélation entre les deux caractères X et Y est d'autant meilleure que $|r|$ est proche de 1 : les deux phénomènes sont en relation étroite dans le mêmes sens.

Définition 2.5.

On appelle **coefficient de détermination** le carré du coefficient de corrélation linéaire. Souvent notée R , on a : $R = r^2$. Le coefficient de détermination mesure la part de variabilité de Y explicable par l'équation de régression de Y en X .

2.4.3 Droite de régression de Y en X

La droite de régression de Y en X est la droite (Δ) passant par le point moyen associé à la série statistique double $(x_i; y_j; n_{ij})$ et dont le coefficient directeur est $a = \frac{Cov(X; Y)}{V(X)}$. Une équation cartésienne de cette droite est :

$$Y - \bar{Y} = \frac{Cov(X; Y)}{V(X)}(X - \bar{X}).$$

2.4.4 Droite de régression de X en Y

La droite de régression de X en Y est la droite (Δ') passant par le point moyen G dont une équation cartésienne est donnée par :

$$X - \bar{X} = \frac{\text{Cov}(X; Y)}{V(Y)}(Y - \bar{Y}).$$

Exemple 2.6. .

En reprenant l'Exemple 2.3, déterminer les équations cartésiennes des droites de régression de Y en X , puis de X en Y .

2.5 Ajustement linéaire : Méthode des points moyens de Mayer

Le principe de cette méthode est le suivant : On partage le nuage de points en deux sous-nuages d'effectifs égaux (ou égaux à une unité près si l'effectif total est impair). On considère pour chaque sous-nuage, un point moyen. Désignons par G_1 le point moyen du premier sous-nuage et par G_2 celui du second sous-nuage. La droite de Mayer est la droite (G_1G_2) . Elle passe par le point moyen G du nuage des points de la série double.

Principe de construction :

1. Ordonner les points du nuage en ordre croissant des x_i , puis les séparer en deux groupes ayant le même nombre de points. Si le nombre de points est impair, le point central doit être placé dans chacun des deux sous groupes ;
2. Calculer la moyenne de X et celle de Y pour chaque sous groupe de points, soit G_1 et G_2 ;
3. Tracer la droite (G_1G_2) passant par ces deux points.

Exemple 2.7. .

Déterminer l'équation cartésienne de la droite de régression de Mayer de la série de l'Exemple 2.3.

2.6 Quelques exercices

Exercice 2.8. .

Pour chaque question, choisir la (les) lettre(s) correspondante(s) à la (aux) bonne(s) réponse(s).

1. Le coefficient de détermination r^2 entre deux variables x et y vaut :

$$\begin{array}{llll} (a) \frac{[\text{cov}(x, y)]^2}{V(x)V(y)} & (b) \frac{a}{a'} & (c) (aa')^2 & (d) \frac{[\text{cov}(x, y)]^2}{\sigma(x)\sigma(y)} \\ (e) \left(\frac{a}{a'}\right)^2 & (f) aa' & (g) \frac{\text{cov}(x, y)}{\sqrt{\sigma(x)\sigma(y)}} & \end{array}$$

2. Des données liées à une série statistique fournissent les informations suivantes :

$\bar{x} \simeq 5,5$; $\bar{y} \simeq 18,75$; $\sigma(x) \simeq 3$; $\sigma(y) \simeq 6,8$; $\text{cov}(x, y) \simeq 17,9$. On a alors :

$$\begin{array}{ll} (a) y \simeq -1,6x + 0,4 & (b) y \simeq 1,99x + 7,8 \\ (c) x \simeq -1,6y + 0,4 & (d) x \simeq 1,99y + 7,8 \\ (e) y \simeq 0,4x - 1,6 & (f) x \simeq 7,8y + 1,99 \end{array}$$

Exercice 2.9. .

Dans la maternité de VEHDJI, on a relevé pour chacune des 10 premières naissances d'une journée l'âge x de la mère et le poids y du nouveau né. On obtient le tableau ci-dessous :

x	20	22	16	18	20	18	22	26	18	20
y	2,8	3	2,4	2,6	2,8	2,4	3	3,2	2,6	3

Observant attentivement ces informations, MIWANOU un étudiant de la ville de VEHDJI se pose la question de savoir si l'on pourrait estimer le poids de son cousin LANI onzième nouveau né de la journée d'une mère de 24 ans qui vient d'accoucher dans cette maternité.

1. Le modèle étudié dans cette partie est appelé "droite de Mayer" : $(\mathcal{D}_1)$.
 - (a) Détermine l'équation de la droite $(\mathcal{D}_1)$ sous la forme de $y = ax + b$.
 - (b) Estime le poids P_1 de LANI avec ce modèle.
2.
 - (a) Déterminer les coordonnées du point moyen $G(\bar{x}, \bar{y})$.
 - (b) Vérifier si G appartient à $(\mathcal{D}_1)$.
3. Détermine la covariance de cette série.
4.
 - (a) Détermine le coefficient de corrélation linéaire de cette série.
 - (b) Un ajustement linéaire convient-il ?
 - (c) Détermine une équation de la droite de régression $(\mathcal{D}_2)$ de x en y .
 - (d) Estime le poids P_2 de LANI.
5. Compare P_1 et P_2

Exercice 2.10.

Une entreprise a mis au point un nouveau produit et cherche à en fixer le prix de vente. Une enquête est réalisée auprès des clients potentiels ; les résultats sont donnés dans le tableau suivant, où y_i représente le nombre d'exemplaires du produit que les clients sont disposés à acheter si le prix de vente, exprimé en milliers de francs, est x_i .

x_i	60	80	100	120	140	160	180	200
y_i	952	805	630	522	510	324	205	84

1.
 - (a) Représenter le nuage de points associé à la série.
 - (b) Calculer le coefficient de corrélation linéaire. La valeur trouvée justifie-t-elle la recherche d'un ajustement linéaire ?
2. Déterminer la droite de régression de Y en X .
3. Les frais de conception du produit se sont élevés à 28 millions de francs ; le prix de fabrication de chaque exemplaire est de 25000 francs.
 - (a) Dédurre de la question précédente que le bénéfice Z , en fonction du prix de vente X , est donné par l'égalité : $Z = -5,956X^2 + 1427,18X - 59957$, où X et Z sont exprimés en milliers de francs.
 - (b) Déterminer, à un francs près, le prix de vente X_0 permettant de réaliser le bénéfice maximum et calculer ce bénéfice Z_0 .

Exercice 2.11.

On donne la série statistique suivante à deux variables :

x_i	1,2	1,4	1,6	1,8	2
y_i	13	12	14	16	a

où a est un nombre réel strictement positif.

Une équation de la droite de régression de y en x est : $(\mathcal{D}_1) : y = 9x + 0,6$.

1. Calculer la moyenne $\bar{X}$.
2. Exprimer la moyenne $\bar{Y}$ en fonction de a .
3. Dédurre la valeur de a .
4.
 - (a) Calculer le coefficient de corrélation linéaire de x et y .
 - (b) La corrélation est-elle forte ?
 - (c) Estimer la valeur y_1 de y pour $x = 3,2$.
5.
 - (a) Déterminer l'équation cartésienne de la droite $(\mathcal{D}_2)$ de régression de Mayer de cette série.
 - (b) Estimer la valeur y_2 de y pour $x = 3,2$.
6. Comparer y_1 et y_2 .

Exercice 2.12.

Le tableau suivant donne la dépense, en millions d'euros, des ménages en produits informatiques (matériels, logiciels, réparations) de 2010 à 2019 :

Année	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019
Rang x_i de l'année	0	1	2	3	4	5	6	7	8	9
Dépense y_i	398	451	423	501	673	956	1077	1285	1427	1490

1. Déterminez les coordonnées de G , point moyen de nuage.
2. Le modèle étudié dans cette question sera appelé "droite de Mayer".

G_1 désigne le point moyen des 5 premiers points du nuage et G_2 celui des 5 derniers points.

(a) Déterminer les coordonnées de G_1 et G_2 .

(b) Donnez l'équation de la droite (G_1G_2) sous la forme $y = ax + b$ (on arrondira les coefficients à 0,1 près)

3. **Ajustement des moindres carrés**

Donner, une équation de la droite d'ajustement affine de y en x , sous la forme $y = mx + p$ par la méthode des moindres carrés (les coefficients seront arrondis à 0,1 près).

4. **Ajustement exponentiel**

Si, on ne s'intéresse qu'aux années 2010 à 2016, la forme du nuage suggère plutôt un ajustement exponentiel.

Pour $0 \leq i \leq 6$, on pose $z_i = \ln(y_i)$.

(a) Recopier et compléter le tableau suivant où z_i est arrondi est arrondi à 10^{-3}

x_i	0	1	2	3	4	5	6
z_i							

- (b) Ecrire une équation de la droite d'ajustement affine de z en x par la méthode des moindres carrés (les coefficients seront arrondis à 10^{-3} près).
- (c) En utilisant cet ajustement, effectuer une prévision sur les dépenses de l'année 2020.